

Analiza danych sprzedażowych

Powtarzalny proces analityczny w Pythonie, SQLite i Quarto

PYTHON

SQLITE

QUARTO

30 000 REKORDÓW

Streszczenie projektu

Projekt analizuje sprzedaż detaliczną na podstawie syntetycznego zbioru 30 000 transakcji z lat 2024-2025. Łączy generowanie danych, zapis do relacyjnej bazy SQLite, analizę w pandas oraz raport HTML tworzony w Quarto. Celem jest pokazanie, jak przygotować powtarzalny przepływ od danych źródłowych do wniosków biznesowych.

Najważniejsze wskaźniki

\$10,86 mln

przychód

30 000

zamówień

\$361,91

średnia wartość zamówienia

5 955

unikalnych klientów

Pytanie analityczne

Jak zmienia się przychód w czasie i które kategorie produktów, regiony oraz kanały sprzedaży mają największy udział w wynikach?

Zakres danych: rekordy są wygenerowane syntetycznie. Nadają się do demonstracji metod i narzędzi, ale nie opisują rzeczywistej firmy ani rynku.

1. Dane i architektura

Zbiór obejmuje okres od 1 stycznia 2024 do 31 grudnia 2025. Każdy wiersz reprezentuje jedno zamówienie i zawiera identyfikator klienta i produktu, datę, kategorię, ilość, cenę, przychód, region oraz kanał sprzedaży.

Pole	Znaczenie
order_id, order_date	Identyfikator i data zamówienia
customer_id, region	Klient i przypisany region
product_id, product_name, category	Produkt oraz jego kategoria
quantity, unit_price, total_price	Liczba sztuk, cena jednostkowa i wartość sprzedaży
sales_channel	Kanał: Online lub Store

Model SQLite

Tabela	Rola w modelu
sales	Tabela faktów: data, klient, produkt, ilość, cena i kanał
customers	Wymiar klienta: identyfikator i region
products	Wymiar produktu: nazwa, kategoria i cena referencyjna

Przepływ pracy

1. Generator syntetyczne dane	2. CSV źródło analizy	3. Python + SQL KPI i model	4. Quarto raport HTML
----------------------------------	--------------------------	--------------------------------	--------------------------

Raport Quarto czyta CSV bezpośrednio. Loader Pythona zapisuje dane do SQLite, a zapytania SQL umożliwiają niezależną kontrolę agregacji. Dzięki temu przykładowy raport można odtworzyć bez konfigurowania bazy.

Narzędzia


Python 3.11, pandas, Matplotlib, SQLite, SQL oraz Quarto z silnikiem Jupyter. Skrypt analityczny zapisuje dodatkowe zestawienia CSV i statyczne wykresy PNG.

2. Metody i najważniejsze wyniki

Dane grupowane są według miesiąca, kategorii, regionu, kanału oraz produktu. Przychód liczony jest jako suma total_price, liczba zamówień jako liczba unikalnych order_id, a średnia wartość zamówienia jako przychód podzielony przez liczbę zamówień.

Obszar	Wynik z bieżącego zbioru	Interpretacja
Rok do roku	2025: \$5,46 mln; 2024: \$5,40 mln	Przychód wzrósł o ok. 1,1%.
Kategoria	Electronics: \$5,85 mln (ok. 53,9%)	Największa część wartości sprzedaży.
Region	North: \$3,41 mln; East: \$2,32 mln	North ma najwyższy, a East najniższy przychód.
Kanał	Online: \$6,09 mln; Store: \$4,76 mln	Online ma wyższy łączny przychód.
Średnia wartość	Store: \$364,86; Online: \$359,64	Store ma nieznacznie wyższe AOV.

Przykładowy widok raportu Quarto



Rysunek 1. Porównanie przychodu kategorii oraz tabela produktów o najwyższym przychodzie. Screen pochodzi z raportu HTML wygenerowanego przez Quarto.

3. Wnioski, ograniczenia i odtworzenie

Wnioski z analizy

W badanym, syntetycznym zbiorze elektronika odpowiada za nieco ponad połowę przychodu. Kanał Online generuje większy łączny przychód, natomiast Store ma trochę wyższą średnią wartość pojedynczego zamówienia. Region North osiąga najwyższy przychód. Miesięczny wykres pokazuje silny wzrost końcówki roku, zgodny z sezonowością celowo wprowadzoną w generatorze danych.

Wyniki regionalne i kanałowe

Region	Przychód
North	\$3 407 478
South	\$2 619 523
West	\$2 512 318
East	\$2 317 991

Kanał	Przychód	AOV
Online	\$6 094 404	\$359,64
Store	\$4 762 906	\$364,86

Ograniczenia

- Dane są syntetyczne i zostały zaprojektowane tak, by odzwierciedlać wybrane wzorce. Nie stanowią dowodu na rzeczywiste zachowania klientów.
- Każdy identyfikator `order_id` występuje raz. Dane nie obejmują wielu pozycji jednego zamówienia, zwrotów, kosztów, marży ani stanów magazynowych.
- Dwa lata danych wystarczają do demonstracji trendów, lecz nie do mocnych wniosków o długookresowej sezonowości. Analiza ma charakter opisowy, nie przyczynowy.

Uruchomienie

Po zainstalowaniu Quarto i zależności z `requirements.txt` raport HTML można wygenerować z katalogu projektu poleceniem:

```
py -3.11 -m pip install -r requirements.txt
quarto render reports/sales_report.qmd
```

Podsumowanie

Projekt demonstruje pełny, powtarzalny cykl analityczny: od przygotowania danych, przez model relacyjny i agregację, po wizualny raport. Jego wartość zaliczeniowa będzie największa, gdy zostanie uzupełniony o wymagania prowadzącego, uzasadnienie metod oraz samodzielną interpretację wyników. Jeśli przedmiot wymaga analizy rzeczywistych danych, zbiór syntetyczny należy zastąpić danymi z podanym źródłem.